

Informe Final — Análisis de Usuarios de una Plataforma de Streaming

Las siguientes secciones reemplazan a las originales para lograr una redacción más natural y fluida, manteniendo el mismo contenido técnico.

3. Decisiones de limpieza y preparación

Para preservar el dataset original, todas las tareas de limpieza se realizaron sobre una copia. Primero se eliminaron los registros duplicados y luego se normalizaron las variables categóricas, unificando diferencias de escritura, mayúsculas, tildes y abreviaturas. Las variantes que no pudieron identificarse con seguridad se dejaron como valores nulos. Después se reemplazaron por nulos las edades fuera del rango esperado y los valores negativos de minutos visualizados y tickets de soporte. También se trataron los valores extremos mediante winsorización con criterio IQR para evitar que errores de carga distorsionaran el análisis sin eliminar usuarios con consumos elevados. Finalmente, se convirtieron las fechas al formato correspondiente y se imputaron los datos faltantes utilizando distintos criterios según cada variable. Gracias a este proceso se conservó el 98,46 % de los registros originales, eliminándose únicamente los duplicados verificados.

4. Hallazgos del análisis exploratorio (EDA)

El análisis exploratorio permitió observar que el tiempo de visualización presenta una distribución con asimetría positiva, es decir, la mayoría de los usuarios consume una cantidad moderada de contenido mientras que un grupo reducido registra valores mucho más altos. La edad muestra una distribución bastante equilibrada, con un promedio cercano a los 33 años.

Al comparar el consumo según el plan de suscripción, se aprecia una diferencia clara: los usuarios Premium son quienes más minutos visualizan por mes, seguidos por los planes Estándar y Básico. En cambio, la edad, el país y el género favorito no muestran diferencias importantes en el comportamiento de consumo.

Además, la correlación entre la edad y el tiempo de visualización es prácticamente nula ($r \approx 0$). Lo mismo ocurre con las demás variables numéricas, lo que indica que cada una aporta información distinta sobre el comportamiento de los usuarios.

5. Componentes principales (PCA)

Para aplicar PCA se utilizaron únicamente las variables numéricas: edad, minutos de visualización y tickets de soporte. Antes del análisis, los datos se estandarizaron mediante StandardScaler para que todas las variables tuvieran la misma escala y ninguna predominara sobre las demás.

Los resultados muestran que la varianza se distribuye casi por igual entre las tres componentes principales, con aproximadamente un 33 % para cada una. Esto indica que existe poca

correlación entre las variables originales, por lo que la reducción de dimensionalidad no permite resumir gran parte de la información en pocas componentes. En términos prácticos, cada variable describe un aspecto diferente del comportamiento de los usuarios y aporta información complementaria.

6. Conclusiones y limitaciones

A partir del análisis realizado, se concluye que el plan de suscripción es el factor que mejor diferencia el nivel de consumo de la plataforma. Los usuarios Premium registran un tiempo de visualización considerablemente mayor que los demás planes. Por otro lado, variables como la edad, el país o el género favorito no presentan una relación clara con el consumo.

El análisis de componentes principales también confirmó que las variables numéricas aportan información diferente entre sí, por lo que ninguna resulta redundante. Entre las principales limitaciones del trabajo se encuentran la cantidad de fechas de login inválidas, la presencia de algunos valores nulos en variables categóricas y el hecho de trabajar con un conjunto de datos estático, sin información temporal que permita analizar la evolución del comportamiento de los usuarios.