

Análisis de Usuarios de Plataforma de Streaming

Informe Final — Proyecto Integrador | Minería de Datos I
Val Martinetti | Junio 2026

1. Contexto y objetivo

Se analizó el dataset **streaming_users_dirty.json** (8.160 registros × 8 columnas) de usuarios de una plataforma de streaming latinoamericana. El objetivo fue comprender qué factores distinguen el comportamiento de consumo de los usuarios, siguiendo el ciclo completo de minería de datos: inspección → limpieza → EDA → PCA → conclusiones. El análisis se implementó en notebooks Jupyter y se comunicó mediante una app Streamlit.

2. Calidad y limpieza de datos

El dataset presentó problemas sistemáticos: 15 variantes de `subscription_plan`, 26 de `country` y 28 de `favorite_genre` apuntan a múltiples sistemas de ingesta sin esquema de validación unificado. Los valores centinela (99.999 en `watch_time`, 99 y 150 en `tickets`) son típicos de sistemas legacy donde el campo no admite NULL.

Paso	Acción	Filas	Retención
0	Dataset original	8.160	100.00%
1	Eliminación de duplicados (126)	8.034	98.46%
2–4	Normalización categóricas (plan/país/género)	8.034	98.46%
5–7	Valores imposibles → NaN (age, tickets, watch_time)	8.034	98.46%
8–9	Winsorización outliers extremos (k=3)	8.034	98.46%
10	Parseo fechas (inválidas → NaT)	8.034	98.46%
11	Imputación diferenciada por mecanismo	8.034	98.46%

Mecanismo MAR detectado: la tasa de faltantes en `watch_time` es 8× mayor en Premium (10.4%) que en Básico (1.3%): la ausencia depende del plan → imputación por mediana de cada plan. Retención estructural final: **98.46%**.

3. Hallazgos del análisis exploratorio (EDA)

Distribución de usuarios:

44.9% Básico | 35.3% Estándar | 19.8% Premium. Edad media: 33 años (distribución simétrica, skew ≈ 0.14). Distribución geográfica uniforme: ~1.150 usuarios por país (sin mercado dominante). Géneros con preferencias similares entre planes.

Hallazgo principal — El plan como diferenciador de consumo:

Plan	Watch time promedio	Diferencia vs. Básico
Básico	~540 min/mes	—
Estándar	~750 min/mes	+39%
Premium	~1.300 min/mes	+140%

Hallazgo secundario — La edad no predice el consumo: correlación edad–`watch_time` $r \approx 0.00$. La línea de tendencia es horizontal: usuarios de todas las edades tienen niveles de consumo similares. El plan, no la edad, determina el comportamiento.

Correlaciones entre variables numéricas: `age`, `monthly_watch_time_mins` y `customer_support_tickets` tienen correlaciones menores a $|0.05|$ entre sí. Las tres capturan dimensiones de variación independientes.

4. Escalamiento y PCA

Escalamiento: `StandardScaler` (Z-score) obligatorio. Sin escalar, `monthly_watch_time_mins` (varianza ~decenas de miles) dominaría el PCA por magnitud numérica, no por relevancia analítica.

Variables de entrada: age (perfil demográfico), monthly_watch_time_mins (intensidad de consumo), customer_support_tickets (demanda de soporte técnico). Se excluyeron user_id (identificador) y categóricas (requieren codificación).

Componente	Varianza explicada	Varianza acumulada	Variable dominante
PC1	~34%	~34%	monthly_watch_time_mins
PC2	~33%	~67%	age + customer_support_tickets
PC3	~33%	100%	(residual)

La distribución uniforme de varianza entre las 3 PCs es consecuencia directa de la baja correlación entre variables: cuando las variables son ortogonales, PCA no puede comprimir. Se retienen 2 componentes (67% de varianza) para habilitar visualización 2D.

5. Conclusiones, limitaciones y próximos pasos

El **plan de suscripción es el eje segmentador más relevante** del dataset: explica las mayores diferencias en comportamiento de consumo y su efecto es consistente en todo el rango etario. La brecha Premium–Básico (+140%) es el hallazgo más accionable para estrategias de conversión y pricing.

Limitaciones:

769 fechas no utilizables (no se puede analizar churn/actividad reciente). Categóricas excluidas del PCA (limitan la potencia del análisis dimensional). Relación plan–consumo es asociación, no causalidad probada. Dataset es un snapshot: sin histórico no hay análisis de tendencias.

Próximos pasos:

1) Incorporar plan_encoded al PCA para mayor separación. 2) Calcular días_desde_last_login como proxy de actividad. 3) Investigar el bug de tracking en cuentas Premium (tasa de nulos 8× mayor). 4) Implementar validación de esquema en el sistema origen para evitar reingreso de los mismos errores.